

מטריצת איומן: $X \in \mathbb{R}^{d \times m}$ ששורותיה הן תכונות. המודותיה הן הדגמות. וקטור תיוג: $y \in \mathbb{R}^m$ ע בעל ערך $y_i = f(x_i)$ עבור z_i רעש כלשהו.																	
Empirical Risk Empirical Risk: עבור פונקציית מחיר $\ell: \mathbb{R}^d \rightarrow \mathbb{R}$																	
$ER(h) = \frac{1}{m} \sum_{i=1}^m \ell(h(x_i), y_i)$																	
Squared Loss (RSS)	$\sum_{i=1}^m (h(x_i) - y_i)^2 = \ h(X) - y\ _2^2$																
Absolute Value Loss	$\sum_{i=1}^m h(x_i) - y_i = \ h(X) - y\ _1$																
0-1 Loss	$\frac{1}{m} \sum_{i=1}^m \mathbb{1}[h(x_i) \neq y_i]$																
Maximum Likelihood בחינת תפילות \mathcal{D} עם פרמטר θ ,																	
Digression Function דוגמיות $x_1, \dots, x_m \stackrel{iid}{\sim} \mathcal{D}$ מאגדירים את הנראות: $L(\theta) = L(\theta x_1, \dots, x_m) = \prod_{i=1}^m p(x_i, \dots, x_m \theta)$																	
MLE (Maximum Likelihood Estimator) : יהי $X = \{x_1, \dots, x_m\}$ קבוצת הדגמות, אז הנראות מרבית:																	
$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta X)$																	
Bias & Variance Bias: הסטייה של המודל מנקודות המדגם (שגיאת ההכללה). Variance: השונות של המודל מהאמת (מדף אחרי הרעש). ככל שקבוצת ההיפותוז גדולה יותר, כך הסטייה קטנה. נובעת מ- Estimation Error																	
גרסייה לינארית $\mathcal{H}_{reg} = \{h(x) h(x) = (w, \begin{pmatrix} 1 \\ x \end{pmatrix}), w \in \mathbb{R}^{d+1}\}$ (וקרא w_0 intercept. נקראים המשוואות)																	
Normal Equations: מעורר ה-RSS שכול $X^T X = 0$. עבור מטריצה סגונה: ההאים הבאים שקולים: 1. קיים פתרון יחיד למערכת. 2. $\dim(Ker(X^T X)) = 0$. 3. $\dim(Ker(X^T)) = 0$. 4. $\sigma_{d+1}(X) > 0$. (בעל נורמה מהימנית).																	
טענות מההוכחה: 1. $Ker(X^T X) = Ker(X^T)$. 2. עבור מטריצה ריבועית, $Im(A^T) = Ker(A)^\perp$. 3. $Im(A^T) = Ker(A)^\perp$. 4. $X^T w = Xy$ למערכת $X^T w = Xy$ אינסוף פתרונות אם $w \perp Ker(X)$. 5. $X^T w = Xy$ למערכת $X^T w = Xy$ אינסוף פתרונות אם $w \perp Ker(X)$.																	
מפספס: $y^T X^T X y$ הוא תמיד פתרון למשוואה הנומלית. הגדרה: אם $X^T X$ כולל עמודה (פיצ'ר) הנפרש e^T יתר העמודות נאמר שהוא מעטט סינגולרי (זלא הפיך). (זלא הפיך).																	
$X^T \epsilon = \sum_{i=1}^n \epsilon_i u_i^T \text{ s.t. } \sum_{i=1}^n \epsilon_i^2 = 1$																	
MLE: עבור $z_i \sim N(0, \sigma^2)$ (כלומר $N(x_i^T w, \sigma^2)$) הצפיפות:																	
$p(y w) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(x_i^T w - y_i)^2}{2\sigma^2}}$																	
$= \frac{1}{(\sqrt{2\pi\sigma^2})^m} \prod_{i=1}^m e^{-\frac{(x_i^T w - y_i)^2}{2\sigma^2}} = L(w y)$																	
נראות מרבית:																	
$\hat{w} = \arg \max_w L(w y) \stackrel{\text{by log}}{=} \arg \min_w \sum_{i=1}^m (x_i^T w - y_i)^2$																	
Bias-Variance Tradeoff: מתקיים- $MSE = \mathbb{E}[(\hat{y} - y)^2] = Var[\hat{y}] + bias^2[\hat{y}]$																	
$= Variance + bias^2$																	
קליסיפיקציה סיווג גיואן: שגיאת Type-I (FP) זו השגיאה החמורה. שגיאת Type-II (FN) זו.																	
<table border="1"> <thead> <tr> <th></th><th>Positive</th><th>Negative</th><th></th></tr> </thead> <tbody> <tr> <td>True</td><td>TP, Recall, TPR: $\frac{TP}{TP + FN}$</td><td>TN, Specificity: $\frac{TN}{TN + FP}$</td><td>Accuracy: $\frac{TP + TN}{TP + TN + FP + FN}$</td></tr> <tr> <td>False</td><td>FP, FPR: $\frac{FP}{FP + FN}$</td><td>FN, FNR: $\frac{FN}{FN + TP}$</td><td>Error Rate: $\frac{FP + FN}{TP + TN + FP + FN}$</td></tr> <tr> <td></td><td>Precision: $\frac{TP}{TP + FP}$</td><td>Negative predictive value: $\frac{TN}{TN + FN}$</td><td>$F_1 = 2 \cdot \frac{\text{Recall} \cdot \text{Precision}}{\text{Recall} + \text{Precision}}$</td></tr> </tbody> </table>			Positive	Negative		True	TP, Recall, TPR: $\frac{TP}{TP + FN}$	TN, Specificity: $\frac{TN}{TN + FP}$	Accuracy: $\frac{TP + TN}{TP + TN + FP + FN}$	False	FP, FPR: $\frac{FP}{FP + FN}$	FN, FNR: $\frac{FN}{FN + TP}$	Error Rate: $\frac{FP + FN}{TP + TN + FP + FN}$		Precision: $\frac{TP}{TP + FP}$	Negative predictive value: $\frac{TN}{TN + FN}$	$F_1 = 2 \cdot \frac{\text{Recall} \cdot \text{Precision}}{\text{Recall} + \text{Precision}}$
	Positive	Negative															
True	TP, Recall, TPR: $\frac{TP}{TP + FN}$	TN, Specificity: $\frac{TN}{TN + FP}$	Accuracy: $\frac{TP + TN}{TP + TN + FP + FN}$														
False	FP, FPR: $\frac{FP}{FP + FN}$	FN, FNR: $\frac{FN}{FN + TP}$	Error Rate: $\frac{FP + FN}{TP + TN + FP + FN}$														
	Precision: $\frac{TP}{TP + FP}$	Negative predictive value: $\frac{TN}{TN + FN}$	$F_1 = 2 \cdot \frac{\text{Recall} \cdot \text{Precision}}{\text{Recall} + \text{Precision}}$														
Half-spaces תחת ההנחה שקיים מפרדי לינארי, נגדיר את הפיכון להיות ERM -min. נמזער לפי קריטריון $L_S(h_w) = \sum_{i=1}^m \mathbb{1}[y_i \cdot (x_i, w) < 0]$																	
$\arg \min_w \sum_{i=1}^m \mathbb{1}[y_i \cdot (x_i, w) < 0]$																	
Perceptron Algorithm: Initialize: $w = \vec{0}$ While $\exists i$ s.t. $y_i \cdot (x_i, w) \leq 0$: $w \leftarrow w + y_i \cdot x_i$																	
SVM $\mathcal{H}_{SVM} = \{x \mapsto \text{sign}((x, w) + b)\}$ מרחק: $D((x_i, w), v) = \min_{v: (v, w) + b = 0} \ x_i - v\ $ שוליים: $M((x_i, w), v) = \min_{x_i \in S} D((x_i, w), v)$ Hard-SVM: $\arg \min_{w, b} \ w\ ^2$ Soft-SVM: $\arg \min_{w, b} \lambda \cdot \ w\ ^2 + \frac{1}{m} \sum_{i=1}^m \xi_i$ $\Leftrightarrow \arg \min_{w, b} \lambda \cdot \ w\ ^2 + \frac{1}{m} \sum_{i=1}^m \max\{1 - y_i \cdot ((x_i, w) + b), 0\}$																	

Bootstrap: בדגום B בקוצות S^B , ובאמן את האלגוריתם עליהם. בכדי לבחון את הביצועים נשתמש ב- $S^B \setminus T^B$ ונמצע כמקודם.

טעיית גנרליזציה:

- Over-estimating generalization error** – כאשר מאמינים על $m \cdot \frac{k-1}{k}$ כמות לא מספקת של דגימות, אז לפי PAC נערך בחסר את השיגאה.
- Under-estimating generalization error** – כאשר אנו מעריכים מודל ע"פ נתונים עליהם אומן (מצב של Overfitting), או כאשר על הדאטה בוצע עיטוי המתאים למודל.

השיגאה בעת שימוש בולידציה

$L_D(h_S) = L_D(h_S) - L_T(h_S) + L_T(h_S) + L_S(h_S) + L_S(h_S)$
 A . שיגאת ההכללה. ניתנת לחסימה תחת ההנחה שפונקציית ה-loss חסומה. B . עבור B גדול ו- k קטן ככל הנראה Underfitting. C . עבור B גדול ככל הנראה Overfitting.

טענה: לכל $\mathcal{H} \in \mathcal{H}$ והכל $(0,1)$:
$$\Pr \left[|L_T(h) - L_D(h)| \leq \sqrt{\frac{\ln(2/\delta)}{m}} \right] \geq 1 - \delta$$

עבור $\mathcal{H}_1 \subseteq \dots \subseteq \mathcal{H}_k$ סופיים.

Standard Method: עבור $\mathcal{H}_{f_k}(S_{all})$:
$$\Pr \left[L_D(h^*) \leq \min_{h \in \mathcal{H}_k} L_D(h) + \sqrt{\frac{21}{m} \ln \left(\frac{2}{\delta} \right)} \right] \geq 1 - \delta$$

Model Selection: עבור $\mathcal{H}_1 \subseteq \dots \subseteq \mathcal{H}_k$:
$$\Pr \left[L_D(h^*) \leq \min_{h \in \mathcal{H}_k} L_D(h) + \sqrt{\frac{2}{m} \ln \left(\frac{2k}{\delta} \right)} + \sqrt{\frac{2}{1-\alpha m} \ln \left(\frac{4|H_k|}{\delta} \right)} \right] \geq 1 - \delta$$

בחירת פיצ'לרים

- מתאם פירסון**:
$$R = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}$$
- Forward-Stepwise Selection** - אלגוריתם חמדן שמתחיל מהחוקר (Intercept) ומוסיף פיצ'לרים עד לכמות k הנקבעת.
- Backward-Stepwise Selection** - אלגוריתם המתחיל מכל הפרמטרים ומוריד כל פעם פרמטר עם המתאם הקטן ביותר.
- Regularization** - שיטה כללית בה מגבילים את כמות הפרמטרים.

בנוסף ניתן לבצע **שינוי של המידע**, למשל מרכזו שלו סביב הראשית, שינוי הטווח (Scaling), ביצוע Standardization ועוד...

Unsupervised Learning

- דוגמאות לשימוש**: 1. חשיפה של מבנה במימד נמוך. 2. קלסיפיקציה. 3. זיהוי אנומליות.

PCA

$$\arg \min_{U \in \mathbb{R}^{d \times k}, W \in \mathbb{R}^{k \times d}} \sum_{i=1}^m \|x_i - UWx_i\|^2$$

משפט: תהי $A = \sum_{i=1}^m x_i x_i^T$, ויהיו u_1, \dots, u_n הו"ע של A (מסודרים בסדר יורד), אז $U = W^T = [u_1 \dots u_k]$ פתרון לבעיית ה-PCA.
 $P = \sum_{i=1}^k u_i u_i^T$ נקראת מטריצת הטלה, היא סימטרית והיא קירוב טוב ביותר ל- x בתת-מרחב:
 $\|x - v\|_2 \geq \|x - Px\|_2 \quad \forall v \in \text{span}\{u_1, \dots, u_k\}$
 \bullet היא שונה מ- IS בו מטילים את הערך y בלבד.
ע"י הזהז של הקבוצות $\tilde{x}_i = x_i - \bar{x}$ אנו מקבלים ב- A את מטריצה השונות: $A = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T$.

גדרות: תהי מטריצת השונות של דגימות אימון x_1, \dots, x_m , כמודרך לעיל, יהיו u_1, \dots, u_d הו"ע של מטריצת השונות המתאמים לע"ע $\lambda_d \geq \dots \geq \lambda_1$.
 \bullet המספר λ_i נקרא **הערך המוביל** ה- i של x_1, \dots, x_m .
 \bullet הקטסור u_i נקרא **הקטסור המוביל** ה- i של x_1, \dots, x_m .
הורדת מימד תהיה $U^T x_i$. לאחר מכן כל קטסור במרחב ניתן לייצוג ע"י הקירוב $\hat{x} = \sum \alpha_i u_i$.

PCA Algorithm:
Input: $X \in \mathbb{R}^{m \times d}$
Eval:

- if $m > d$:
 - $A = X^T X$
 - u_1, \dots, u_k eigenvectors of A
- else ($m \leq d$):
 - $B = XX^T$
 - v_1, \dots, v_k eigenvectors of B
 - denote $u_i = \frac{1}{\|x^T v_i\|} X^T v_i$
- return u_1, \dots, u_k

בטבל לבהור את k ניתן לייצר Scree Plot (גרף בו מציגים את הר"ע בסדר יורד).

Clustering
נגיד חלוקה של המידע x_1, \dots, x_m ל- k מחלקות C_j ו- μ_j . נגדיר את פונקציית המחיר (ע"פ פונקציית מרחק d) ע"י:
$$G(C_1, \dots, C_k) = \min_{\mu_1, \dots, \mu_k} \sum_{j=1}^k \sum_{x \in C_j} d(x, \mu_j)^2$$

Centroid: הערך (C_j, μ_j) המינימלי.
טענה: אם $\mathcal{X} = \mathbb{R}^d$ ו- d היא הנורמה האוקלידית, אז centroid-הו הממוצע $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$.

k-means Algorithm:
Input: x_1, \dots, x_m and $k \in \mathbb{N}$
Step 0: choose initial μ_1, \dots, μ_k
Until convergence:

- set C_j to be the points x_i closer to μ_j than to any other centroid.
- update μ_j to centroid of C_j :

$$\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$$

החלוקה המושגת מ- μ_1, \dots, μ_k נקראת Voronoi cells.

תכונות: השונות בכל C_j יורדת בכל איטרציה. האלגוריתם תמיד מתכנס. האלגוריתם מתכנס למינימום מקומי (בהתאם לנקודות ההתחלה).

Convex Optimization
פונקציה קמורה: תהי C קבוצה קמורה. פונקציה $f: C \rightarrow \mathbb{R}$ נקראת קמורה אם:
$$\forall u, v \in C, \alpha \in [0,1] \quad f(\alpha v + (1-\alpha)u) \leq \alpha f(v) + (1-\alpha)f(u)$$

משפט: חיתוך של קבוצות קמורות הוא קמור. A_{α} ו- A_{β} .
אפיגרף: $epi(f) = \{(x,t) | f(x) \leq t\}$
פונקציה f קמורה אם $epi(f)$ קבוצה קמורה אם α
לכל $x, y \in \text{dom}(f)$ מתקיים $f(y) \geq f(x) + \nabla f(x)^T (y-x)$
(תנאי מסדר ראשון) **אם $\nabla^2 f(x) \succcurlyeq 0$ (תנאי מסדר שני).**
תכונות השומורות על קמירות:

- סכום חיובי** - עבור f_1, \dots, f_n קמורות, $\alpha_1, \dots, \alpha_n \geq 0$ אז $f = \sum \alpha_i f_i$ קמורה.
- הרכבה עם אפינית** - $g(x) = f(Ax + b)$ קמורה על $\{x | Ax + b \in \text{dom}(f)\}$.
- מקסימום** - אם לכל $y \in A$ מתקיים $f(x, y)$ קמורה ב- x , אז $g(x) = \sup_{y \in A} f(x, y)$ קמורה.
- מינימום** - אם $f(x, y)$ קמורה במשותף ($\nabla^2 f \succcurlyeq 0$) ו- S קמורה, אז $g(x) = \inf_{y \in S} f(x, y)$ קמורה. (לא תמיד).

תכונות מינימום
משפט: אם f קמורה, כל מינימום מקומי הוא גלובלי.
משפט: תהי f קמורה דפרנציבילית ו- $f(u) \leq f(v)$ אז:
$$\nabla f(u) \geq f(v) + (\nabla f(u), u-v)$$

תכונות סאב-גרדיאנט
סאב-גרדיאנט: הקטור w הוא סאב-גרדיאנט של w אם:
$$\forall u \quad f(u) \geq f(w) + (v, u-w)$$

סימון: זכור קבוצת סאב-הגרדיאנטים של w בקבוצה w .
למה: f קמורה אם $\nabla f(w)$ לכל נקודה $w \in \text{dom}(f)$ מתקיים $\partial f(w) \neq \emptyset$. אם $\partial f(w)$ דפרנציבילית ב- x אז $\partial f(x) = \{ \nabla f(x) \}$.
טענה: ניח $f: V \rightarrow \mathbb{R}$ קמורה, ותהי $f_i(v) = \max_x f_i(v)$. כמו כן עבור $u \in V$ נסמן $j \in \arg \max f_i(u)$. אז $\partial f(u) \subseteq \partial f(u)$.
מסקנה: ניח $f: V \rightarrow \mathbb{R}$ קמורה. תהי $w \in V$ עבורה $\partial f(w) \neq \emptyset$, אז w מינימום גלובלי של f .

תכונות ליפשיץ
ליפשיץ: פונקציה $f: C \rightarrow \mathbb{R}$ נקראת ρ -ליפשיץ אם:
$$\forall w_1, w_2 \in C \quad |f(w_1) - f(w_2)| \leq \rho \|w_1 - w_2\|$$

למה: אם f קמורה, אז f היא ρ -ליפשיץ אם ∇f הנורמה של כל סאב-גרדיאנט של f הוא לכל היותר ρ .

אופטימיזציה קמורה
בעיית אופטימיזציה:
$$\min_x f_0(x) \quad s.t. \quad f_i(x) \leq b_i \quad \forall i = 1, \dots, n$$

בעיית אופטימיזציה קמורה: בעיית אופטימיזציה עם f_i קמורות. **בעיית תכנון ליניארי**: בעיית אופטימיזציה עם f_i ליניארים.
בעיית למידה קמורה: בעיית למידה \mathcal{H}, \mathcal{F} מעל $\mathcal{X} \times \mathcal{Y}$ תקרא קמורה אם מחלקת ההיפותזות \mathcal{H} היא קבוצה קמורה, ולכל $(x, y) \in \mathcal{X} \times \mathcal{Y}$ הפונקציה $\ell(h(x), y)$ קמורה ב- h .
דוגמה: $ERM_{\mathcal{H}}$.
טענה: לא כל הבעיות הקמורות מעל \mathbb{R}^d הן למידות-PAC.
טענה: בעיה קמורה מעל \mathbb{R}^d , כך ש- \mathcal{H} חסומה ל- ℓ ליפשיץ, היא למידה-PAC.
 \bullet **חסומה** - קיים B עבורו $\|w\| \leq B \quad \forall w \in \mathcal{H}$.
 \bullet **ליפשיץ** - הפונקציה $\ell(h(x), y)$ קמורה ב- h והיא ρ -ליפשיץ.
במקרה זה סיבוכיות הדגימה תלויה רק ב- ρ, B, ϵ .

Sub-gradient Descent Algorithm:
initialize: $w^{(1)} = 0$
for $t = 1, \dots, T$:

- Choose $v_t \in \partial f(w^{(t)})$
- $w^{(t+1)} \leftarrow w^{(t)} - \eta \cdot v_t$

return $\bar{w} = \frac{1}{T} \sum_{t=1}^T w^{(t)}$

משפט: תהי f פונקציה קמורה, ρ -ליפשיץ, ויהי $w^* \in \arg \min_w f(w)$. אם נרץ את האלגוריתם Sub-GD על במשך T צעדים עם $\frac{\|w^*\|^2}{\rho^2 T}$, אז הקטסור \bar{w} המוחזר מקיים:
$$f(\bar{w}) \leq f(w^*) + \frac{\|w^*\|^2 \rho}{\sqrt{T}}$$

מסקנה: תהי f פונקציה קמורה, ρ -ליפשיץ, ויהי $w^* \in \arg \min_w f(w)$. לכל $\epsilon > 0$ אם נרץ את האלגוריתם Sub-GD על f במשך $\frac{\|w^*\|^2 \rho^2}{\epsilon^2}$ צעדים עם $\frac{\|w^*\|^2 \rho^2}{\epsilon^2}$, אז הקטסור \bar{w} המוחזר מקיים:
$$f(\bar{w}) \leq f(w^*) + \epsilon$$

מסקנה: האלגוריתם Sub-GD צריך $\frac{\|w^*\|^2 \rho^2}{\epsilon^2}$ איטרציות בכדי להתכנס.
Stochastic Gradient Descent Algorithm:
initialize: $w^{(1)} = 0$
for $t = 1, \dots, T$:

- Choose $(x, y) \sim \mathcal{D}$
- Choose $v_t \in \partial \ell(w^{(t)}, (x, y))$
- $w^{(t+1)} \leftarrow w^{(t)} - \eta \cdot v_t$

return $\bar{w} = \frac{1}{T} \sum_{t=1}^T w^{(t)}$

למה: תהי בעיית למידה קמורה-ליפשיץ-חסומה עם פרמטרים p, B . אז לכל $\epsilon > 0$, אם נרץ את האלגוריתם SGD למעור w עם מספר איטרציות $T \geq \frac{B^2 \rho^2}{\epsilon^2}$ ועם $T \geq \frac{B^2}{\rho^2 \epsilon^2}$, אז הפלט של SGD מקיים:
$$\mathbb{E}[L_D(\bar{w})] \leq \min_{w \in \mathcal{H}} L_D(w) + \epsilon$$

טענה: אלגוריתם \mathcal{A} הילמד בעזרת SGD הוא לומד-חלש.

נדאי לזכור

Class	Vcdim
Axis aligned rectangles	4
Homogeneous Halfspaces	d
Non- Homogeneous Halfspaces	$d + 1$
Polynomial Thresholds (Pol_r)	$\leq \binom{d+r-1}{d}$
k-interval	$2k$
Conjunctions	d
sin	∞

תזכורת: בשביל $VCDim(\mathcal{H}) = d$ צריך להראות שקיימת מחלקה מגודל d מנותצת, ושכל מחלקה בגודל $d+1$ לא ניתן לנתץ.

ההבדלים בשיגאות:

- Generalization error**: $L_D(h)$
- Training error / empirical error**: $L_S(h)$
- Approximation error**: $\min_h L_D(h)$
- Estimated error**: $L_D(h) - \min_h L_D(h')$

לשים לב: כאשר נגדיל את T Adaboost-1 (כלומר את מספר הילומדים החלשים) אנו נשפר את ה-Approximation error (ובהתאם את ה-Estimated error).

Bias-Variance Tradeoff: יהי $h_S = h^* + \epsilon_{approximation} + \epsilon_{estimation}$

$L_D(h_S) = L_D(h^*) + L_D(h_S) - L_D(h^*)$

אז: $\mathcal{A}(S)$

KNN		
Low Bias	Small \xrightarrow{k} Big	High Bias
Low Var	Big \xleftarrow{k} Small	High Var

Decision Tree		
Low Bias	Deep \xleftarrow{height} Shallow	High Bias
Low Var	Shallow \xrightarrow{height} Deep	High Var

Linear Regression		
Low Bias	$(d \sim m)$	High Bias
Low Var	$(d \ll m)$	High Var

Regularization		
Low Bias	$0 \xrightarrow{\lambda} \infty$	High Bias
Low Var	$\infty \xleftarrow{\lambda} 0$	High Var

Bagging		
Bias	Dosen't change	Bias
Low Var	Big(∞) \xrightarrow{T} Small	High Var

Adaboost		
Low Bias	Big(∞) \xleftarrow{T} Small	High Bias
Low Var	Small \xrightarrow{T} Big(∞)	Var goes up a bit

Clustering		
Low Bias	Big \xleftarrow{k} Small	High Bias
Low Var	Small \xrightarrow{k} Big	High Var

אלגברה ליניארית

טענה: עבור מטריצה $A \in \mathbb{R}^{m \times n}$:

- $\mathbb{R}^m = \mathcal{C}(A) \oplus \mathcal{N}(A^T), \quad \mathbb{R}^n = \mathcal{C}(A^T) \oplus \mathcal{N}(A)$
- משפט**: עבור מטריצה $A \in \mathbb{R}^{m \times n}$ הבאים שקולים:
- $rank(A) = m$ מדרגה מלאה
 - $\det(A) \neq 0$
 - $im(A) = \mathbb{R}^m$
 - $\ker(A) = \{0\}$

מתקיים:

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \Rightarrow A^{-1} = \frac{1}{\det(A)} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

מטריצת סיבוב: מטריצה אורתוגונלית ($AA^T = A^T A = I$), $\det(A) = 1$ עבורה

$$A = \begin{pmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{pmatrix}$$

הטלה: $u \cdot \frac{u}{\|u\|} = \frac{(u,u)}{\|u\|^2} \cdot u$

הסתברות

שערך תוחלת: $\hat{\mu} = \frac{1}{m} \sum_{i=1}^m x_i$
שערך שונות: $\hat{\sigma}^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \hat{\mu})^2$
שערך מטריצת Covariance:
$$\hat{C} = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T$$

מתאם פירסון: בין X, Y מ"מ אי-שלילי:

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y}$$

אי-שוויון מרקוב: עבור X מ"מ אי-שלילי: $\Pr[X \geq t] \leq \frac{\mathbb{E}[X]}{t}$
אי-שוויון צ'בישב: $\Pr[|X - \mathbb{E}[X]| \geq t] \leq \frac{\text{Var}[X]}{t^2}$
אי-שוויון הופדינג: עבור X_1, \dots, X_n כך ש- $b_i \leq X_i \leq a_i$:
$$\Pr[|X - \mathbb{E}[X]| \geq t] \leq 2e^{-\frac{\sum_{i=1}^n (a_i - b_i)^2}{2t^2}}$$

טענה: עבור מטריצה A (קבועה), ווקטור מקרי Z מתקיים:
$$\text{Var}[AZ] = A \cdot \text{Var}[Z] \cdot A^T$$

אינפי

גרדיאנט: $\nabla f = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)$

יעקוביאן: $J_x(f) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_m}{\partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_1}{\partial x_n} & \dots & \frac{\partial f_m}{\partial x_n} \end{pmatrix} = \begin{pmatrix} | & & | \\ \nabla f_1 & \dots & \nabla f_m \\ | & & | \end{pmatrix}$
כלל השרשרת: $J_x(g \circ f) = J_{f(x)}(g) \cdot J_x(f)$
הסייאן:

$$H(f) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

נגזרות מפורסמות:

$$\nabla \left(\|w\|^2 \right) = 2w, \quad J_w(A \cdot w) = A, \quad J_x(f) = (\nabla f)^T$$